Actividad Redes Neuronales Profundas - Problema 1
 Andrés Alejandro Guzmáz González - A01633819
 Llamado a librerías

```
1 import tensorflow as tf
2 import matplotlib.pyplot as plt
3 from tensorflow.keras import datasets, layers, models
```

Carga de datos

```
1 (train_images, train_labels),(test_images, test_labels) = datasets.cifar10.load_data()
```


Proceso de normalización de las imágenes

```
1 train_images, test_images = train_images/255.0, test_images/255.0

1 # Validación de respuestas "Labels"
2 print(train_labels)

[[6]
    [9]
    [9]
    ...
    [9]
    [1]
    [1]]
```

Mostramos un grid con el ejemplo de las imágenes



```
Capas de convolución
1 # Agrego las primeras 3 capas de convolución
2 model = models.Sequential()
3 # En la primer capa es necesario definir el tamaño de entrada de las imágenes
4 model.add(layers.Conv2D(64, (3,3), activation='relu', input_shape=(32,32,3)))
5 model.add(layers.MaxPooling2D((2,2)))
6 model.add(layers.Conv2D(128, (3,3), activation='relu'))
7 model.add(layers.MaxPooling2D((2,2)))
8 model.add(layers.Conv2D(128, (3,3), activation='relu'))
Arquitectura
1 model.summary()

→ Model: "sequential_2"

     Laver (type)
                                 Output Shape
                                                            Param #
```

conv2d\_6 (Conv2D) (None, 30, 30, 64) 1792 max\_pooling2d\_4 (MaxPoolin (None, 15, 15, 64) g2D) conv2d\_7 (Conv2D) (None, 13, 13, 128) 73856 max\_pooling2d\_5 (MaxPoolin (None, 6, 6, 128) 0 g2D) conv2d\_8 (Conv2D) (None, 4, 4, 128) 147584 Total params: 223232 (872.00 KB) Trainable params: 223232 (872.00 KB) Non-trainable params: 0 (0.00 Byte)

## Capas densas

```
1 # Se agregan las capas densas a la red
2 model.add(layers.Flatten())
3 model.add(layers.Dense(128, activation='relu'))
4 model.add(layers.Dense(20, activation='sigmoid'))
```

## 1 model.summary()

Epoch 4/10

Epoch 5/10

Model: "sequential 2"

Layer (type)	Output Shape	Param #
conv2d_6 (Conv2D)	(None, 30, 30, 64)	1792
max_pooling2d_4 (MaxPoolin	(None, 15, 15, 64)	0
g2D)		
conv2d 7 (Conv2D)	(None, 13, 13, 128)	73856
	(),,	
max pooling2d 5 (MaxPoolin	(None 6 6 128)	0
g2D)	(None, 0, 0, 120)	0
gzD)		
24 0 (620)	(N 4 4 120)	147504
conv2d_8 (Conv2D)	(None, 4, 4, 128)	147584
63 = (53 )	(1)	
flatten_5 (Flatten)	(None, 2048)	0
dense_10 (Dense)	(None, 128)	262272
dense 11 (Dense)	(None, 20)	2580
Total params: 488084 (1.86 M	B)	
Trainable params: 488084 (1.	,	
··		


Non-trainable params: 0 (0.00 Byte)

```
1 ...
2 Se procede a hacer el entrenaiento de la red y se definen la función de
3 optimización, la función de pérdida y las épocas de entrenamiento.
4 ''
5 model.compile(optimizer='adam',
        loss=tf.keras.losses.SparseCategoricalCrossentropy(from_logits=True),
6
        metrics=['accuracy'])
8 history = model.fit(train_images, train_labels, epochs=10, validation_data=(test_images,test_labels))
  Epoch 1/10
  Epoch 2/10
  1563/1563 [=
         Fnoch 3/10
  1563/1563 [=
```

## Evaluacion

```
1 # Gráfica para mostrar el accuracy de la red en cada época
2 plt.plot(history.history['accuracy'], label='accuracy')
3 plt.plot(history.history['val_accuracy'], label='val_accuracy')
4 plt.xlabel('Epoch')
5 plt.ylabel('Accuracy')
6 plt.ylim([0.5,1])
7 plt.legend(loc='lower right')
```

<matplotlib.legend.Legend at 0x7a13bed4fd60>



## Predicción

Pruba con un dato random del conjunto de imágenes para validar si la red lo clasifica correctamente

```
1 n = 110 # Número de imagen
2
3 plt.figure(figsize=(2,2))
4 plt.imshow(test_images[n])
5 plt.xlabel(class_names[test_labels[n][0]])
6 plt.show()
```

